

第2回 代表値の性質と、その嘘

「平均的な人」は実在するか

統計学I (B) 北星学園大学

小野原 彩香

今日のゴール

1. 平均・中央値・最頻値の**性質の違い**
2. 平均が「順位上の真ん中」「最も多い値」を表すとは限らない
3. 外れ値は**消していいのか**を判断できる

到達目標 **G1 (記述統計)**

第1回の復習

そして、実際にあった間違い

第1回で確認したこと

- 直感は「なんとなく」ではなく、**一定の向きに**裏切る
- モンティ・ホールの答えは、条件を整理すれば **計算だけで出せる**
- 地図：**記述統計**（第2～3回）→ **推測統計**（第6回以降）

今日はその入口、**記述統計の1回目**

第1回の課題：パートAの誤答（83名中6名）

設問	人数	間違いの中身
A4（回数とばらつき）	3名	回数を増やすと何が変わるかの取り違い
A1（ドアを変えるか）	2名	「変えない」を選んだ
A3（誕生日）	1名	「23人だから約23%」（正しくは約51%）
A2（勝率）	1名	—

足すと7になるのは、A1とA2の両方を誤った人が1名いるため

記号は正答でも、本文に **別の数字** を書いた答案も1名
（「(ウ) 約67%」を選んで「約90%」と記述）

つまずき① 「理論値=1万回のときの値」

理論値 $2/3$ は **計算で出る値**。試行回数とは無関係

なぜ起きる？

Colab の画面では、理論値と1万回の実測値が
同じ場所に並んで現れる

→ 「1万回で出た数字が理論値」とつながってしまう

つまずき② 「回数を増やすと当たる確率が上がる」

上がるのは **確率**ではなく、**推定の精度**
「変える」の勝率は **1回目からずっと $2/3$**

なぜ起きる？

グラフの線が $2/3$ に「上がっていく」ように見える
動いているのは **観測された割合** なのに、
確率そのものが動いたと読んでしまう

→ 2つを同じ言葉で呼んでいるのが原因

つまずき③ 回数を1つしか試していない (約15名)

設問は「**回数を変えるとどうなるか**」

1つだけでは、比べるものがない

なぜ起きる？

1万回で理論値にぴたり合うと「**確かめられた**」と感じる

でも **少ない回数ですれること**を見ないと、

回数が効いているのかは分からない

この3つは、今日そのまま出てくる

第1回のつまずき	今日どこに現れるか
① 理論値と実測値を同一視	「平均」は計算で出る値。 典型的な人ではない
② 2つを同じ言葉で呼ぶ	平均・中央値・最頻値を**ぜんぶ「真ん中」**と呼ぶ
③ 1つしか試さず結論	代表値1つでは分布の形は分らない

とくに② — 日常語の「真ん中」でまとめると、今日の話は全部ぼやける

3つの代表値

代表値	定義	ひとことで
平均値	全部足して個数で割る	等しく分けたら一人いくら
中央値	順に並べた真ん中	ちょうど真ん中の人
最頻値	最も多い値	いちばんありがちな値

どれも「代表」。でも別物。

式の読み方 — $\sum$ に慣れる

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

記号	指しているもの
x_i	i 番目のデータ (i は番号を入れる箱)
n	データの個数 (霊長類なら 265)
$\sum_{i=1}^n$	$x_1 + x_2 + \cdots + x_n$ の略記。新しい計算ではない
$\bar{x}$	平均。横棒は「平均をとった」という印

× よくある誤り： $\sum$ をかけ算と思う / 「 x を n 倍」と読む

中央値と最頻値には、この式がない

- **中央値** ... 順番に並べる 手順
- **最頻値** ... 数えて一番多いものを選ぶ 手順

1本の式で書けるかどうか、
3つの代表値の **違いのひとつ**

クイズ

ニュース：「日本人の**平均**貯蓄額は〇〇万円」

あなたの実感より、高くない？


その違和感、正しいかもしれない。

霊長類 265種の体重

代表値	値
平均値	5,881 g
中央値	3,006 g
最大値	149,325 g (ヒガシゴリラ) ← 犯人
最小値	31 g (ネズミキツネザル)

**平均は中央値のほぼ2倍。 **最大と最小は4,800倍ちがう

なぜズれる？



右に裾を引く → 平均（赤）が山より右へ引っ張られる

外れ値を除くと...

	平均	中央値
全265種	5,881 g	3,006 g
ヒト科7種を除く	4,127 g	2,797 g

- 平均は**1,754g も動く**（外れ値に弱い）
- 中央値は**209g しか動かない**（頑健 robust） → 動いた量は **8.4倍** 違う

外れ値は消していい？

→ 理由を言えるかどうか

- 入力ミス（身長1710cm）→ 訂正・除外OK
- 本物の富裕層 → 勝手に消すのは**改ざん**（結果を歪める不適切な処理）
- 「平均を下げたいから消す」→ **禁じ手**

迷ったら「中央値で報告」or「両方示す」

対称に近いと、平均と中央値は近づく

妊娠期間日 : 平均164.4日 / 中央値165.5日 (歪度 -0.06) → ほぼ同じ

最頻値まで一致するとは限らない (例: 1,1,2,3,4,5,5 は平均=中央値=3、最頻値は1と5)

体重では、少数の大きな値が平均を押し上げ、中央値との差が大きくなった。

一方この妊娠期間では、平均と中央値が近かった。

だから――**まず分布の形 (ヒストグラム) を見る。**

発展

平均と中央値は「同じ問い」への2つの答え

代表値を「決め方」から逆に考える

データを **1つの数 c** で代表させる。
 c が代表として **どれだけ下手か** を点数にして、
その点数がいちばん小さい c を探す。

下手さの測り方を変えると、**出てくる答えが変わる**

データが 1, 2, 6 だけのとき

候補 c	ズレを二乗して合計	ズレの絶対値を合計
1	26	6
2	17	5 ← 最小
3	14 ← 最小	6
4	17	7
6	41	9

同じデータなのに **最小の場所が違う**
二乗 $\rightarrow c = 3 =$ **平均** / 絶対値 $\rightarrow c = 2 =$ **中央値**

なぜ二乗や絶対値？ —— 符号を消すため

$c = 3$ のとき、ズレは $-2, -1, +3$

そのまま足すと 0。打ち消してしまう

符号の消し方は2つ —— 二乗するか 絶対値をとるか

この選択が、平均と中央値の分かれ目

絶対値のほうは「引っ越し先」の問題

数直線上に何人か住んでいる。全員が集まる場所を決めたい

$A(c)$ = 全員が歩く距離の合計

候補地を **右に1歩** 動かすと...

- c より**左**の人 ... 1歩分 **遠くなる** (損)
- c より**右**の人 ... 1歩分 **近くなる** (得)

→ 得か損かは **左右どちらに人が多いか** だけで決まる

→ **釣り合う場所=中央値**

だから中央値は外れ値に強い

候補 c	左	右	右に動かすと
1.5	1個	2個	得
2	1個	1個	釣り合い ← 中央値
3	2個	1個	損

「誰がどれだけ遠くに住んでいるか」は一度も使っていない
使ったのは 人数（順位） だけ

→ ゴリラが149kgでも1,490kgでも、順位が同じなら中央値は動かない

まとめ

代表値の選択は中立ではない

どれを選ぶかは、すでに一つの「主張」

数字を見たら、まず分布の形を疑え

次回：ばらつきを測る（分散・標準偏差）