

# 第3回 ばらつきを測る

## 正規分布という「仮定」

統計学I (B) 北星学園大学

小野原 彩香

## 今日のゴール

1. 分散・標準偏差が何を測っているか
2. 偏差値の正体
3. 正規分布の 68-95-99.7 則 と、「正規だと仮定してよいか」の確かめ方

到達目標 **G1** (記述統計)

# 前回の答案から 冒頭で確認する4つ

## 第2回の結果

52名提出 / 記述は38名が満点

減点した14名のつまずきは **4つの型** に分かれた

どれも今日の「ばらつき」に直接ひびく

## ① 最多 —— 「とりあえず消すのが危険な理由」が未記述（3名）

B2が求めたのは3点

除いてよい例 / 除いてはいけない例 / **なぜ危険か**

異常値（記録の誤り）と本物の極端な値を  
**区別せずに消すと、本物の情報まで失われる**  
だから消す前に **なぜ外れているのかを確かめる**

## ② 除いてよい／いけないの取り違い (4名)

| 書かれていたこと               | どこが違うか                      |
|------------------------|-----------------------------|
| 10万円の出品は「相場に不相応だから除く」  | <b>極端だから消す</b> ＝禁じ手。実在すれば本物 |
| ゴリラ149kgは「中央値から遠いから除く」 | 中央値から遠いことは理由にならない           |
| 入力ミスを「除いてはいけない」側に (2名) | 入力ミスは <b>除いてよい</b> 側        |

## 除いてよいのは、この3つだけ

1. 欠測コード (−999 のような符号)
2. 入力・測定 of 誤り (訂正、できなければ理由を明示)
3. 対象範囲の限定 (目的と手続きを明示)

**「平均から遠い」「極端だ」は理由にならない**

理由になるのは **その値が測りたいものを測れていない** という根拠

### ③ ヒト科除外を「外れ値除去の例」として引いた (2名)

「ヒト科7種を除くと平均は1,754g動くが中央値は209g」

これは **外れ値除去**ではない

|         |                      |
|---------|----------------------|
| 外れ値除去   | ある値を「おかしい」と判断して取り除く  |
| 対象範囲の限定 | 「ヒト科以外の霊長類」を分析対象と決める |

結論は同じでも **やった操作が違う**

## ④ 与えられた数値の書き写し間違い (1名)

アルバイトの時給は **1,050円** (1,500円ではない)

結論は変わらないが、代表値の話は

**「どの数字を代表させるか」**

→ 元の数字は正確に写す


## 今日につながること

外れ値は、代表値よりも **ばらつきに強く効く**

**二乗する**ので、遠い値の影響がさらに大きくなる

①②でつまずいた人は、今日も同じところで迷う

## クイズ：2つの森、どちらも平均6.0kg



同じような群れ？

## 平均だけでは分らない

- 森A：ほとんどが6kg前後 ( $SD \approx 0$ )
- 森B：半分2kg・半分10kg ( $SD \approx 4.1$ )

平均は分布の「位置」しか表さない。  
足りないのは「散らばり」＝ばらつき。

## ばらつきの測り方

1. 各データの **平均からの差** (偏差)
2. プラスマイナスが打ち消す → **二乗して平均 = 分散**
3. 単位が日<sup>2</sup>で読めない → **ルートで戻す = 標準偏差(SD)**

| 妊娠期間日 | 値                         |
|-------|---------------------------|
| 平均    | 164.4 日                   |
| 分散    | 1,427.2 (日 <sup>2</sup> ) |
| 標準偏差  | <b>37.8 日</b> ← これを使う     |

# 偏差値の正体


$$\text{偏差値} = 50 + 10 \times \frac{\text{値} - \text{平均}}{\text{標準偏差}}$$

平均50・SD10 に置き直した **相対位置**

| 種            | 生スケール        | 対数スケール |
|--------------|--------------|--------|
| ネズミキツネザル 31g | 45.5         | 23.2   |
| ニホンザル 10kg   | 53.2         | 59.9   |
| ヒガシゴリラ 149kg | <b>159.2</b> | 77.1   |


同じ80点でも、集団のSDが違えば偏差値は変わる

# 正規分布と 68-95-99.7 則



| 範囲   | 理論    | 対数体重   | 生の体重  |
|------|-------|--------|-------|
| ±1SD | 68%   | 71.7%  | 97.4% |
| ±2SD | 95%   | 94.7%  | 97.4% |
| ±3SD | 99.7% | 100.0% | 98.5% |

## でも、すべてが正規ではない



生の体重の歪度 **+7.60** (対数なら  $-0.40$ )。正規曲線がまるで合わない。

しかも **平均 $-1$ SD =  $-7,254$ g**。体重がマイナスの動物はいない。

「正規だと仮定する」は判断

自然法則ではない

- 68-95-99.7則も、後で習う多くの手法も「正規」前提
- **どの量について、何のために正規性を仮定するのかを確認する**  
(例：回帰で問題になるのは多くの場合、変数そのものではなく**モデルの誤差**)
- 鉄則：**まずヒストグラムで形を見る**

## まとめ

平均は「位置」、SDは「幅」

両方見て初めてデータが分かる

正規分布は便利な仮定 — 当てはまるかは自分で確かめる

次回：Python統計処理入門（自分でコードを書く）