

第3回 ばらつきを測る

正規分布という「仮定」

統計学I (B) 北星学園大学

小野原 彩香

今日のゴール

1. 分散・標準偏差が何を測っているか
2. 偏差値の正体
3. 正規分布の 68-95-99.7 則 と、「正規だと仮定してよいか」の確かめ方

到達目標 **G1** (記述統計)

前回の答案から 冒頭で確認する4つ

第2回の結果

52名提出 / 記述は38名が満点

減点した14名のつまずきは **4つの型** に分かれた

どれも今日の「ばらつき」に直接ひびく

① 最多 —— 「とりあえず消すのが危険な理由」が未記述（3名）

B2が求めたのは3点

除いてよい例 / 除いてはいけない例 / **なぜ危険か**

異常値（記録の誤り）と本物の極端な値を
区別せずに消すと、本物の情報まで失われる
だから消す前に **なぜ外れているのかを確かめる**

② 除いてよい／いけないの取り違い (4名)

書かれていたこと	どこが違うか
10万円の出品は「相場に不相応だから除く」	極端だから消す ＝禁じ手。実在すれば本物
ゴリラ149kgは「中央値から遠いから除く」	中央値から遠いことは理由にならない
入力ミスを「除いてはいけない」側に (2名)	入力ミスは 除いてよい 側

除いてよいのは、この3つだけ

1. 欠測コード (−999 のような符号)
2. 入力・測定 of 誤り (訂正、できなければ理由を明示)
3. 対象範囲の限定 (目的と手続きを明示)

「平均から遠い」「極端だ」は理由にならない

理由になるのは **その値が測りたいものを測れていない** という根拠

③ ヒト科除外を「外れ値除去の例」として引いた (2名)

「ヒト科7種を除くと平均は1,754g動くが中央値は209g」

これは **外れ値除去ではない**

外れ値除去	ある値を「おかしい」と判断して取り除く
対象範囲の限定	「ヒト科以外の霊長類」を分析対象と決める

結論は同じでも **やった操作が違う**

④ 与えられた数値の書き写し間違い (1名)

アルバイトの時給は **1,050円** (1,500円ではない)

結論は変わらないが、代表値の話は

「どの数字を代表させるか」

→ 元の数字は正確に写す


今日につながること

外れ値は、代表値よりも **ばらつきに強く効く**

二乗するので、遠い値の影響がさらに大きくなる

①②でつまずいた人は、今日も同じところで迷う

クイズ：2つの森、どちらも平均6.0kg



同じような群れ？

平均だけでは分らない

- 森A：ほとんどが6kg前後 ($SD \approx 0$)
- 森B：半分2kg・半分10kg ($SD \approx 4.1$)

平均は分布の「位置」しか表さない。
足りないのは「散らばり」＝ばらつき。

ばらつきの測り方

1. 各データの **平均からの差** (偏差)
2. プラスマイナスが打ち消す → **二乗して平均 = 分散**
3. 単位が日²で読めない → **ルートで戻す = 標準偏差(SD)**

妊娠期間日	値
平均	164.4 日
分散	1,427.2 (日 ²)
標準偏差	37.8 日 ← これを使う

偏差値の正体


$$\text{偏差値} = 50 + 10 \times \frac{\text{値} - \text{平均}}{\text{標準偏差}}$$

平均50・SD10 に置き直した **相対位置**

種	生スケール	対数スケール
ネズミキツネザル 31g	45.5	23.2
ニホンザル 10kg	53.2	59.9
ヒガシゴリラ 149kg	159.2	77.1

同じ80点でも、集団のSDが違えば偏差値は変わる

正規分布と 68-95-99.7 則



範囲	理論	対数体重	生の体重
±1SD	68%	71.7%	97.4%
±2SD	95%	94.7%	97.4%
±3SD	99.7%	100.0%	98.5%

生の体重の 97.4% が2つ並ぶのは誤植ではない

範囲を広げたのに1種も増えていない

	なぜ
下側	平均 -1SD が -7,254 g。下に広げても入る種はいない
上側	+1SD (19,016 g) ~ +2SD (32,150 g) に該当種が1種もない

その外側 (+2SD~+3SD) には3種いる

→ ピグミーチンパンジー 35,120 g・スマトラオランウータン 39,696 g・チンパンジー 45,000 g


→ だから ±3SD で 98.5% に増える

ヒストグラムに穴があいている

釣鐘型なら、平均から外へ途切れずに減っていくはず

→ この穴そのものが「正規ではない」証拠

でも、すべてが正規ではない



生の体重の歪度 **+7.60** (対数なら -0.40)。正規曲線がまるで合わない。

しかも **平均 -1 SD = $-7,254$ g**。体重がマイナスの動物はいない。

「正規だと仮定する」は判断

自然法則ではない

- 68-95-99.7則も、後で習う多くの手法も「正規」前提
- **どの量について、何のために正規性を仮定するのかを確認する**
(例：回帰で問題になるのは多くの場合、変数そのものではなく**モデルの誤差**)
- 鉄則：**まずヒストグラムで形を見る**

まとめ

平均は「位置」、SDは「幅」

両方見て初めてデータが分かる

正規分布は便利な仮定 — 当てはまるかは自分で確かめる

次回：Python統計処理入門（自分でコードを書く）