第3回　ばらつきを測る

正規分布という「仮定」

統計学I（B）　北星学園大学
小野原 彩香

今日のゴール

1. 分散・標準偏差が**何を測っているか**
2. 偏差値の正体
3. 正規分布の 68-95-99.7 則 と、**「正規だと仮定してよいか」の確かめ方**

到達目標 **G1（記述統計）**

前回の答案から

冒頭で確認する4つ

第2回の結果

52名提出 / 記述は38名が満点

減点した14名のつまずきは **4つの型** に分かれた

どれも今日の「ばらつき」に直接ひびく

① 最多 ——「とりあえず消すのが危険な理由」が未記述（3名）

B2が求めたのは3点
除いてよい例 / 除いてはいけない例 / **なぜ危険か**

> 異常値（記録の誤り）と本物の極端な値を
> **区別せずに消すと、本物の情報まで失われる**
> だから消す前に **なぜ外れているのかを確かめる**

② 除いてよい／いけないの取り違え（4名）

書かれていたこと	どこが違うか
10万円の出品は「相場に不相応だから除く」	**極端だから消す**＝禁じ手。実在すれば本物
ゴリラ149kgは「中央値から遠いから除く」	中央値から遠いことは理由にならない
入力ミスを「除いてはいけない」側に（2名）	入力ミスは**除いてよい**側

除いてよいのは、この3つだけ

1. **欠測コード**（−999 のような符号）
2. **入力・測定の誤り**（訂正、できなければ理由を明示）
3. **対象範囲の限定**（目的と手続きを明示）

「平均から遠い」「極端だ」は理由にならない

理由になるのは **その値が測りたいものを測れていない** という根拠

③ ヒト科除外を「外れ値除去の例」として引いた（2名）

「ヒト科7種を除くと平均は1,754g動くが中央値は209g」

これは **外れ値除去ではない**

外れ値除去	ある値を「おかしい」と判断して取り除く
対象範囲の限定	「ヒト科以外の霊長類」を分析対象と決める

結論は同じでも **やった操作が違う**

④ 与えられた数値の書き写し間違い（1名）

アルバイトの時給は **1,050円**（1,500円ではない）

結論は変わらないが、代表値の話は
「どの数字を代表させるか」

→ 元の数字は正確に写す

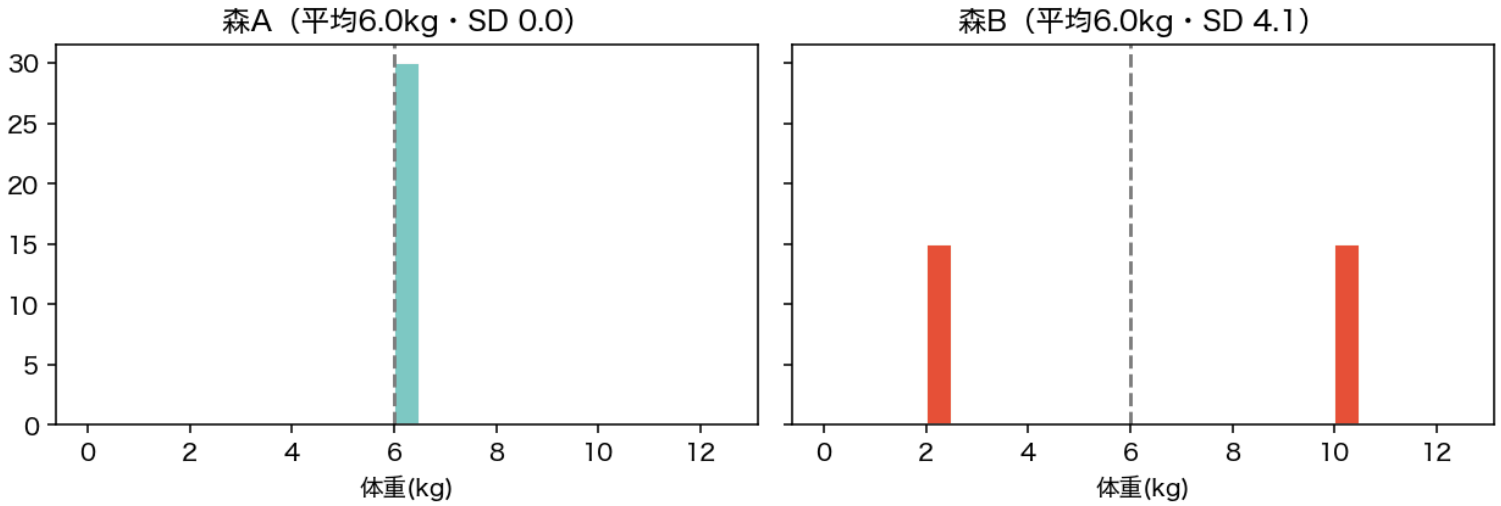
今日につながること

外れ値は、代表値よりも **ばらつきに強く効く**

二乗するので、遠い値の影響がさらに大きくなる

①②でつまずいた人は、今日も同じところで迷う

クイズ：2つの森、どちらも平均6.0kg



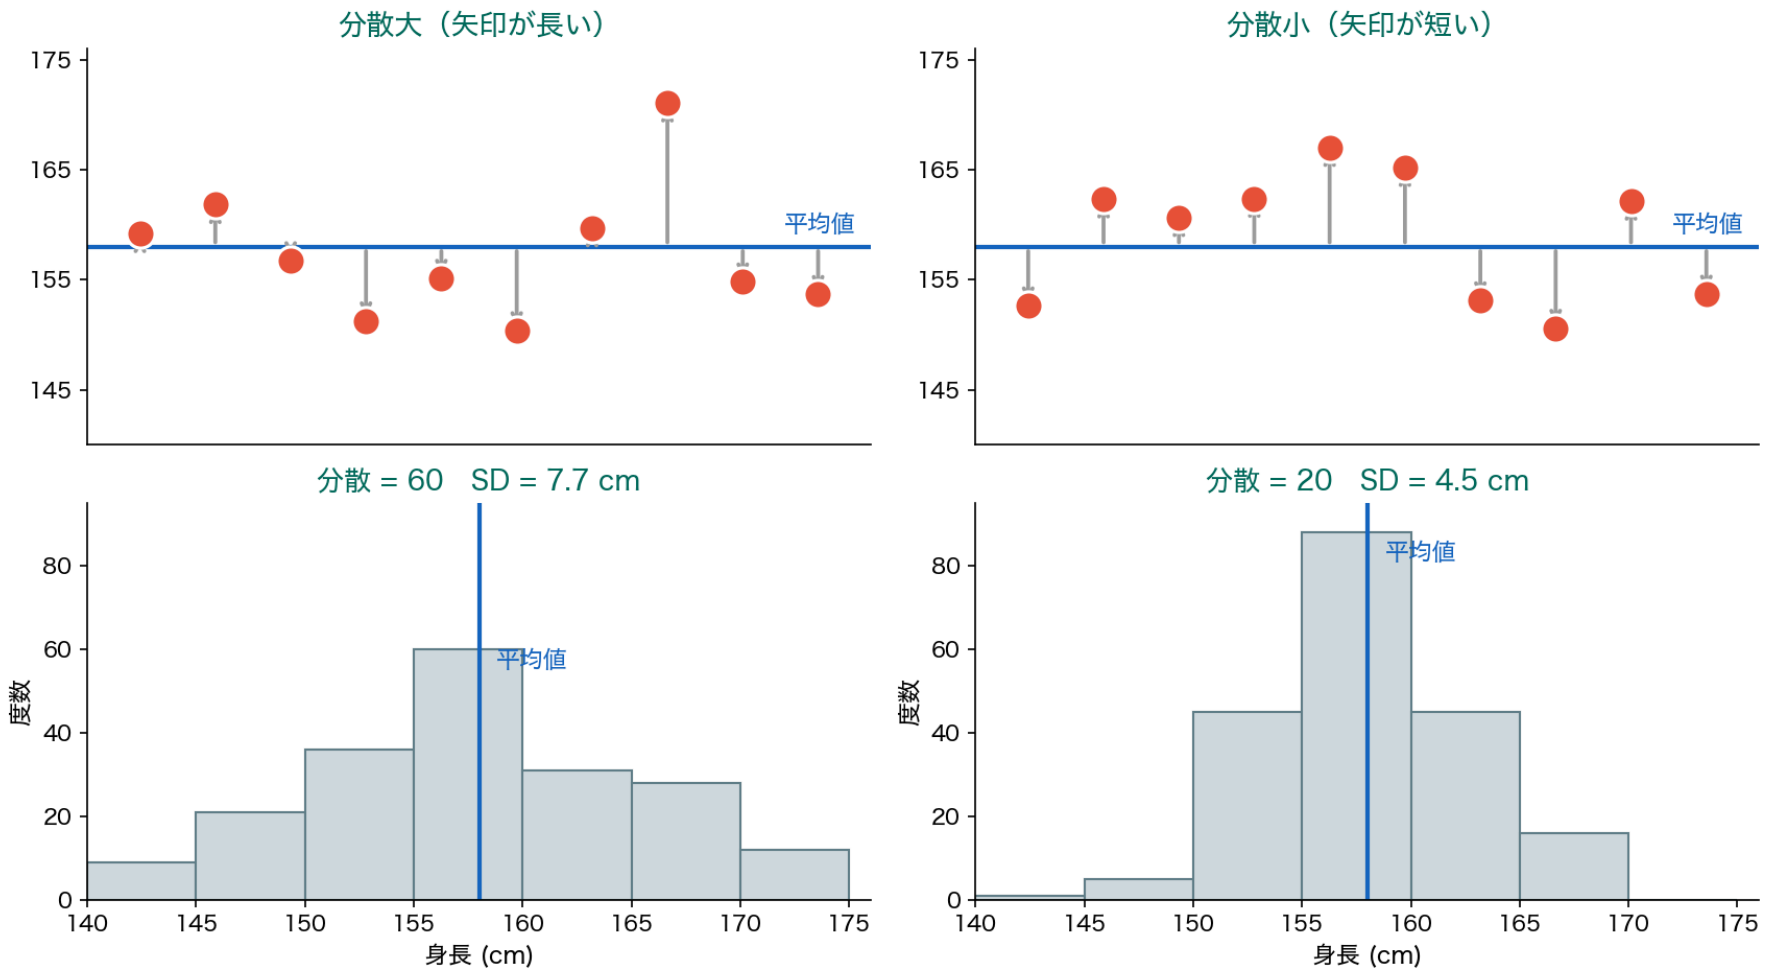
同じような群れ？

平均だけでは分からない

- 森A：ほとんどが6kg前後（SD ≈ 0）
- 森B：半分2kg・半分10kg（SD ≈ 4.1）

平均は分布の **「位置」** しか表さない。
足りないのは **「散らばり」＝ばらつき**。

分散が大きい／小さいとは



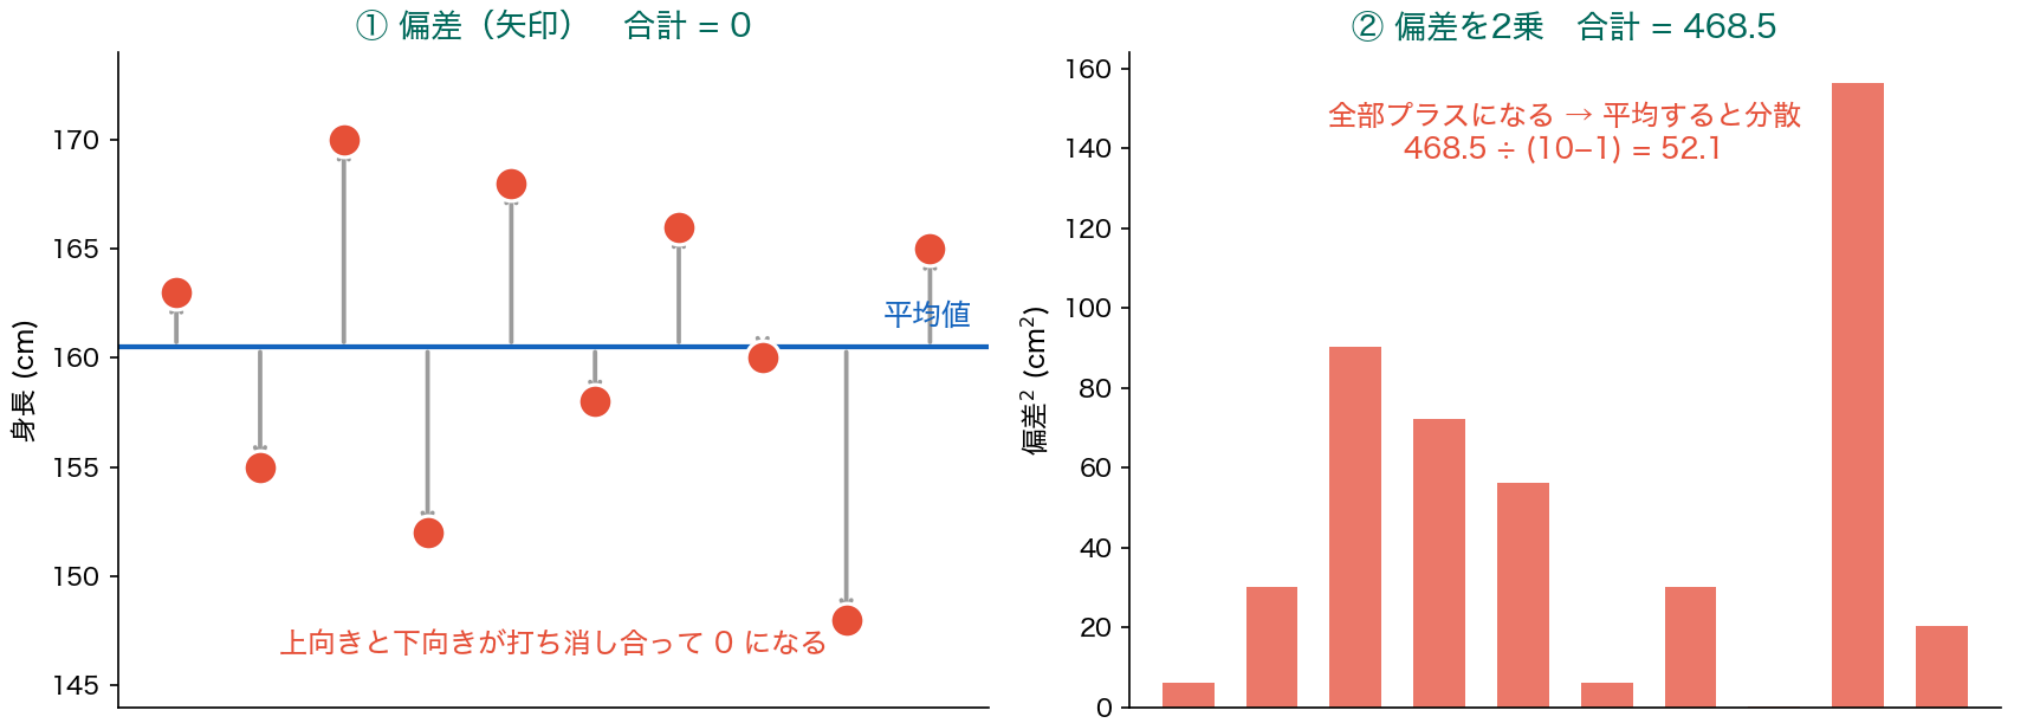
平均はどちらも158cm。違うのは矢印の長さだけ

ばらつきの測り方

1. 各データの **平均からの差**（偏差）
2. プラスマイナスが打ち消す → **二乗して平均 ＝ 分散**
3. 単位が日²で読めない → **ルートで戻す ＝ 標準偏差(SD)**

妊娠期間日	**値**
平均	164.4 日
分散	1,427.2（日²）
標準偏差	**37.8 日** ← これを使う

分散のイメージ ―― なぜ二乗するのか



矢印の長さ（偏差）を **二乗して足し、データ数−1で割る** ＝ 分散

偏差値の正体

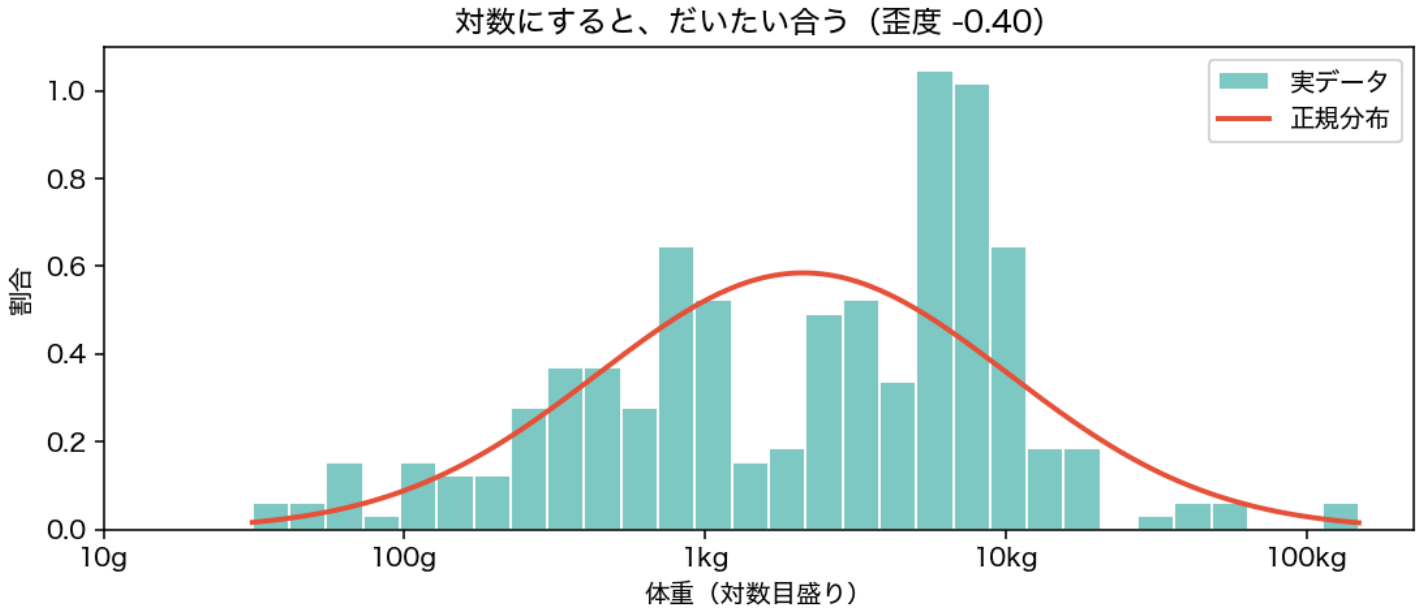
$$偏差値 = 50 + 10 \times \frac{値 - 平均}{標準偏差}$$

平均50・SD10 に置き直した **相対位置**

種	生スケール	対数スケール
ネズミキツネザル 31g	45.5	23.2
ニホンザル 10kg	53.2	59.9
ヒガシゴリラ 149kg	**159.2**	77.1

同じ80点でも、集団のSDが違えば偏差値は変わる

正規分布と 68-95-99.7 則



範囲	理論	対数体重	生の体重
±1SD	68%	71.7%	97.4%
±2SD	95%	94.7%	97.4%
±3SD	99.7%	100.0%	98.5%

生の体重の 97.4% が2つ並ぶのは誤植ではない

範囲を広げたのに1種も増えていない

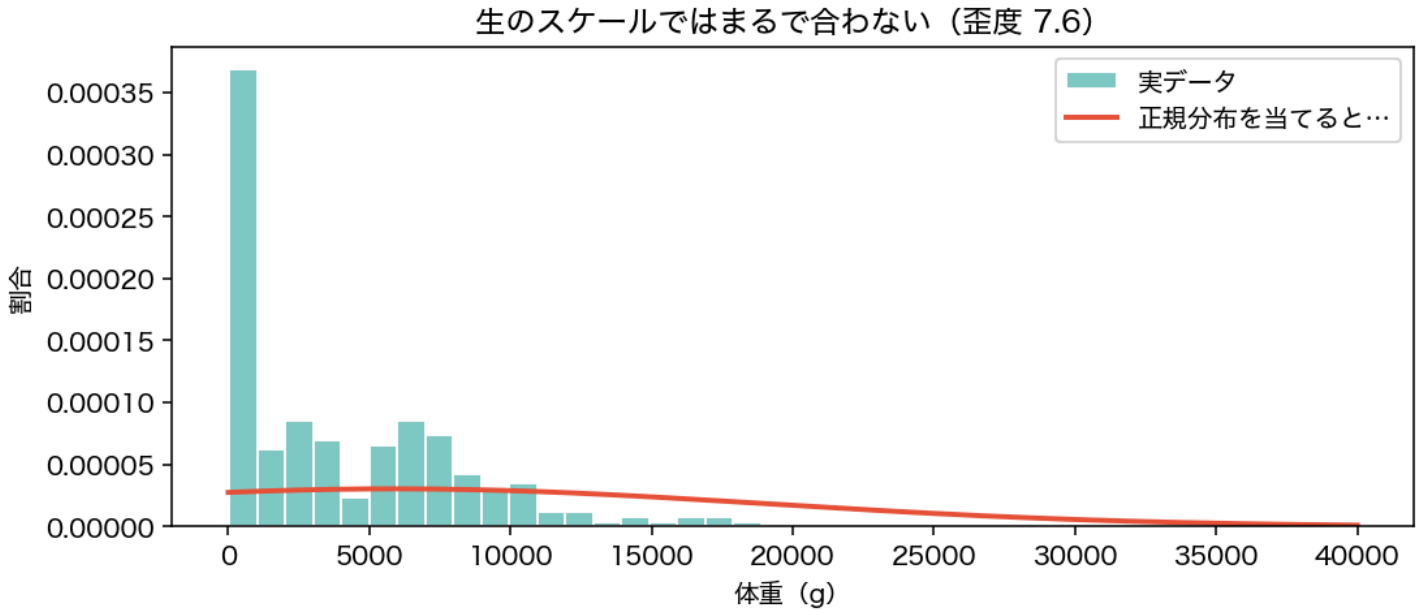
	なぜ
下側	平均 −1SD が **−7,254 g**。下に広げても入る種はいない
上側	**+1SD（19,016 g）〜 +2SD（32,150 g）に該当種が1種もない**

その外側（+2SD〜+3SD）には3種いる
→ ピグミーチンパンジー 35,120 g・スマトラオランウータン 39,696 g・チンパンジー 45,000 g
→ だから ±3SD で 98.5% に増える

ヒストグラムに穴があいている

釣鐘型なら、平均から外へ**途切れずに**減っていくはず
→ **この穴そのものが「正規ではない」証拠**

でも、すべてが正規ではない



生の体重の歪度 **+7.60**（対数なら −0.40）。正規曲線がまるで合わない。

しかも **平均−1SD = −7,254g**。体重がマイナスの動物はいない。

「正規だと仮定する」は判断

自然法則ではない

- 68-95-99.7則も、後で習う多くの手法も「正規」前提
- **どの量について、何のために**正規性を仮定するのかを確認する
  （例：回帰で問題になるのは多くの場合、変数そのものではなく**モデルの誤差**）
- 鉄則：**まずヒストグラムで形を見る**

まとめ

平均は「位置」、SDは「幅」

両方見て初めてデータが分かる

正規分布は便利な仮定 ーー 当てはまるかは自分で確かめる

次回：Python統計処理入門（自分でコードを書く）