

第4回 Python統計処理入門

計算は機械に、判断は人間に

統計学I (B) 北星学園大学

小野原 彩香

今日から、あなたがコードを書く

ここまで電卓・グラフ用紙でやってきた人、お疲れさま。

これからは1秒です

第2・3回の代表値・ばらつきを、今日は**自分のコード**で。

やるのは空欄 を埋めるだけ。

エラーは失敗ではない

エラーメッセージ = 「ここが違うよ」という**お知らせ**

- `KeyError: '列名'` → 列名のスペル違い
- `SyntaxError` → カッコ・全角/半角・インデント
- 文字化け □□ → `japanize` のセルを実行したか

落ち着いて読めば、原因はたいてい書いてある。

データは「表」 = DataFrame

```
df = pd.read_csv(URL)    # 表を読み込む  
df.shape                # (種数, 列数)  
df.head()               # 先頭5行
```

行 = 1つの種

列 = 体重・妊娠期間などの項目

代表値をコードで（第2回の再現）

```
df["体重g"].mean()      # 平均   → 5880.9  
df["体重g"].median()    # 中央値 → 3006.0  
df["体重g"].mode()      # 最頻値 → 992.4   ← ?  
df["一腹産子数"].mode() # 最頻値 → 1.01
```

電卓で出した値と**同じ**。違いは速さと正確さだけ。

最頻値 992.4 g — 動くけれど意味が出てこない

中央値は 3,006 g なのに、最頻値は 992.4 g。真ん中から遠い

なぜ？

265種のうち 992.4 g がたまたま6回出てきただけ

体重はほぼ連続量 → 255通りの値のうち2回以上出るのは6つだけ

いっぽう 一腹産子数の 1.01 は意味がある

209種のうち74種がこの値 → 「ふつう一度に1頭産む」

最頻値が使えるのは、同じ値が繰り返し現れるデータ

第3回の偏差値159と同じ —

計算が通ることと、意味が通ることは別

ばらつき・要約・集計

```
df["妊娠期間日"].std()           # SD → 37.8
df["体重g"].describe()           # 一気に要約
df.groupby("科")["体重g"].mean()  # 科別平均
df.isna().sum()                  # 欠損の確認
plt.hist(df["体重g"].dropna())    # グラフ1行
```

手計算なら数十分 → 一瞬

まとめ

やりたいこと	コード
列を取り出す	<code>df["列名"]</code>
平均/中央値/最頻値	<code>.mean() .median() .mode()</code>
標準偏差/分散	<code>.std() .var()</code>
要約	<code>.describe()</code>
グループ集計	<code>df.groupby("列")["列"].mean()</code>
欠損	<code>df.isna().sum()</code>

まとめ

計算は機械に任せ

人間は「どの数字を信じるか」に集中する

次回：相関と因果 —— 「相関」と「因果」の決定的な違い