第4回　Python統計処理入門

計算は機械に、判断は人間に

統計学I（B）　北星学園大学
小野原 彩香

今日から、あなたがコードを書く

ここまで電卓・グラフ用紙でやってきた人、お疲れさま。

これからは1秒です

第2・3回の代表値・ばらつきを、今日は**自分のコード**で。
やるのは空欄 `____` を埋めるだけ。

前回の答案から ―― 第3回の記述

満点24名（49%）／平均57.0点

今回から「**今日のColabで確認した数値を最低1つ引用する**」を実際に適用

多かった型	人数
① ノートの数値を引いていない	**13名**
② 設問の片方が書かれていない	5名
③ SDの値から外れ値を断定した	3名
④ 因果が逆／数値の取り違え	各2名

① いちばん多かったのは、これ

> **仮に**生の体重の歪度が正の値であれば、右に長い裾を持つ分布だと分かる

ノートには **+7.60** と出ている。なのに仮定の話にしてしまった。

自分で出した数字は、仮定ではなく事実

「生の体重の歪度は+7.60だった」―― これだけで通過する。

もう1つ惜しい例：「妊娠期間の歪度が**ほぼ0**なのに正規分布ではなかった」
指摘は今回いちばん鋭い。**−0.06 と書けばよかっただけ。**

④ そして、今日いちばん効くのがこれ

> 生のスケールの体重の**歪み**は **7.254** であった

- 歪度 **+7.60** … 分布の形を表す指標（**単位なし**）
- 平均−1SD **−7,254 g** … ありえない体重（**単位はg**）

7.254 という数字は、ノートのどこにもない。

機械は数字を出す。それが何の数字かは言わない

`df["体重g"].mode()` → `992.4`
―― 意味のある最頻値かどうかは、**画面には出てこない。**

計算は機械に、判断は人間に。 今日の課題B1は、ここを聞いている。

エラーは失敗ではない

エラーメッセージ＝「ここが違うよ」という**お知らせ**

- `KeyError: '列名'` → 列名のスペル違い
- `SyntaxError` → カッコ・全角/半角・インデント
- 文字化け □□ → japanize のセルを実行したか

落ち着いて読めば、原因はたいてい書いてある。

データは「表」＝ DataFrame

```
df = pd.read_csv(URL)    # 表を読み込む
df.shape                 # (種数, 列数)
df.head()                # 先頭5行
```

行 ＝ 1つの種

列 ＝ 体重・妊娠期間などの項目

代表値をコードで（第2回の再現）

```
df["体重g"].mean()        # 平均   → 5880.9
df["体重g"].median()      # 中央値 → 3006.0
df["体重g"].mode()        # 最頻値 → 992.4   ← ？
df["一腹産子数"].mode() # 最頻値 → 1.01    ← ？
df["科"].mode()           # 最頻値 → オナガザル科
```

電卓で出した値と**同じ**。違いは速さと正確さだけ。

最頻値 992.4 g ―― 計算は通る。では何を表す？

`.mode()` ＝ **データに最も多く記録されている値**

- 体重の記録がある265種のうち、992.4 g が **6種**でいちばん多い
- その6種は、いずれも**同じ Callicebus 属**（なぜ同じ値かはCSVからは不明）
- 連続量では、測定精度・丸め・まとめ方で「同じ値の回数」が変わる

中央値3,006 gから離れていること自体は誤りではない（歪んだ分布では普通）
最多でも、分布の山や典型的な体重を表すとはかぎらない → ヒストグラムも見る

> 第3回の偏差値159と同じ ――
> **計算が通ることと、その数字をどう読めるかは別**

一腹産子数 1.01 ―― 1行が何を表しているか

子の数なのに**小数**。この列は**種ごとに整理・調整された代表値**だから
（この表では1.01が**74種**。「1.01頭生まれる」ではない）

数えているのは**種**であって、**出産ではない**

同じ値が繰り返し現れる列なら、最頻値はそのまま読める

```
df["科"].mode()           # → オナガザル科
df["科"].value_counts()   # → オナガザル科 132種
```

＝「この表にいちばん多く入っている科」と、そのまま解釈できる

ばらつき・要約・集計

```
df["妊娠期間日"].std()                    # SD → 37.8（日）
df["妊娠期間日"].var()                    # 分散 → 1427.2（日²）
df["体重g"].describe()                    # 一気に要約
df.groupby("科")["体重g"].mean()          # 科別平均
df.isna().sum()                           # 欠損の確認
plt.hist(df["体重g"].dropna())            # グラフ1行
```

手計算なら数十分 → **一瞬**

分散の単位は**2乗**（日²）。`.std()` / `.var()` の分母は既定で **n−1**

まとめ

やりたいこと	コード
列を取り出す	`df["列名"]`
平均/中央値/最頻値	`.mean()` `.median()` `.mode()`
標準偏差/分散	`.std()` `.var()`
要約	`.describe()`
グループ集計	`df.groupby("列")["列"].mean()`
欠損	`df.isna().sum()`

まとめ

計算は機械に任せ

人間は「どの数字を信じるか」に集中する

次回：相関と因果 ——「相関」と「因果」の決定的な違い