

第10回 回帰分析

単回帰と重回帰 — データを数式で説明する

統計学I (B) 北星学園大学

小野原 彩香

フック


「**通学時間**でテスト点を予測できる？」

直線を引いてみると... $R^2 \approx 0$

通学時間では予測できない（直線ほぼ水平）

では **勉強時間** なら？

単回帰：勉強 → テスト点



$$\text{テスト点} \approx 45.5 + 7.5 \times \text{勉強時間}$$

傾き7.5 = 勉強1時間で予測+7.5点 / $R^2=0.36$

回帰の言葉

- 傾き(回帰係数) : x が1増えると予測がいくつ増えるか
- 切片 : $x=0$ のときの予測値
- R^2 (決定係数) : ばらつきのうち説明できた割合(0~1)

⚠ 係数 $\neq$ 因果

「勉強1hで+7.5点」は予測上の関連。因果の保証ではない


重回帰：複数の変数で

$$\text{点} \approx 42.4 + 6.6 \text{ 勉強} + 1.0 \text{ 睡眠} - 0.8 \text{ SNS}$$

各係数＝「他を一定にしたとき」の関連（統制）

SNSの -0.8 ＝勉強・睡眠が同じ人で比べたSNSの効果

R^2 の罟：足せば必ず上がる



でたらめな乱数を20本足すだけで R^2 0.36→0.41

R^2 が高い $\neq$ 良いモデル

中身がゴミでも、変数を足せば R^2 は盛れる

= 過学習の入り口

手元に合わせすぎ → 未来は当たらない

「当てはまり」 vs 「複雑さ」をどう釣り合わせる？ → 次回AIC

他の罫：外挿と残差

- **外挿**：勉強20h を式に入れると予測 **196点**（あり得ない）
→ データ範囲の外は予測できない
- **残差**（実際-予測）は必ずプロット。偏りがないか見る

まとめ

モデルは現実の近似

当てはまりの良さ $\neq$ 良いモデル

係数を因果と読まず、範囲外を予測せず、残差を見る

次回：モデル選択とAIC（オッカムの剃刀）