

第10回 回帰分析

単回帰と重回帰 ― データを数式で説明する

統計学I (B) 北星学園大学
小野原 彩香

フック


「**栄養段階**（草食/雑食）で行動圏を予測できる？」

直線を引いてみると... **$R^2 \approx 0$**

$R^2=0.0001$ 。まったく説明できない

では **体重** なら？

単回帰：体重 → 行動圏（両対数）



$$\log(\text{行動圏}) \approx -3.883 + 0.933 \times \log(\text{体重})$$

傾き0.933＝体重10倍で行動圏8.6倍 / $R^2=0.462$ (n=153種)

回帰の言葉

- 傾き(回帰係数) : x が1増えると予測がいくつ増えるか
- 切片 : $x=0$ のときの予測値
- R^2 (決定係数) : ばらつきのうち説明できた割合(0~1)

⚠ 係数 $\neq$ 因果

「体重10倍で行動圏8.6倍」は予測上の関連。因果の保証ではない


重回帰：複数の変数で

$$\log \text{行動圏} \approx -3.36 + 0.568 \log \text{体重} + 0.828 \log \text{集団サイズ}$$

各係数 = 「**他を一定にしたとき**」の関連（統制）

SNSの-0.8 = 勉強・睡眠が同じ人で比べたSNSの効果

R^2 の罟：足せば必ず上がる



でたらめな乱数を50本足すだけで R^2 0.46→0.67

R^2 が高い $\neq$ 良いモデル

中身がゴミでも、変数を足せば R^2 は盛れる

= 過学習の入り口

手元に合わせすぎ → 未来は当たらない

「当てはまり」 vs 「複雑さ」をどう釣り合わせる？ → 次回AIC

他の罫：外挿と残差

- **外挿**：1トンの霊長類を入れると **52km²**。エラーは出ないが、そんな種はいない
→ データ範囲の外は予測できない
- **残差**（実際-予測）は必ずプロット。偏りがないか見る

まとめ

モデルは現実の近似

当てはまりの良さ $\neq$ 良いモデル

係数を因果と読まず、範囲外を予測せず、残差を見る

次回：モデル選択とAIC（オッカムの剃刀）