

第11回 モデル選択とAIC

当てはまり vs 複雑さ — オッカムの剃刀

統計学I (B) 北星学園大学
小野原 彩香

フック

変数を増やせば R^2 は上がり続ける (第10回)


じゃあ全部入れる？

それで“未来”は当たる？

過学習を、目で見える

データを 訓練7割／テスト3割 に分けて、見せてない方で予測

当てはまりは上がり続けるのに予測は途中から悪化＝過学習



当てはまり↑なのに予測は途中から悪化 = 過学習

当てはまり $\neq$ 予測

訓練 R^2 は上がり続ける（手元に合わせるのが上手くなる）
でもテスト誤差は途中から悪化

R^2 を最大化してはいけない

狙うのは「未知データの予測」

AIC：手元だけで予測の良さを見積もる


$$AIC = -2(\text{当てはまり}) + 2(\text{パラメータ数})$$

- 当てはまり良 → 第1項↓ (AIC下がる)
- 変数多い → 第2項↑ (ペナルティ)
- **AICが小さいほど良い**

= オッカムの剃刀の定量化

R²最大 と AIC最小 は一致しない

R²最大とAIC最小は一致しない



R²最大=M3 (でたらめ入り) / AIC最小=M2 (採用)

AICの作法

- **相対指標**：絶対値に意味なし。**差**で比べる（2以上で意味、10で決定的）
- 同じデータ・同じ目的変数で比較
- 「候補の中でのベスト」であって真のモデルの保証ではない

✗ 「AICの絶対値に意味」 ✗ 「変数が多いほど良い」

まとめ

R^2 最大のモデルとAIC最小のモデルは違う

当てはまりと複雑さのバランスで選ぶ

次回：ベイズ統計の入り口 — データで信念を更新する